

1. **Data Preprocessingdan 4 ta basic savol va har biriga 5 tadan follow-up savol**
2. **Yangi dataset topib, classification va regression uchun alohida K-Fold Cross Validation qilish**

1. Data Preprocessing Savollari

1-savol: Data preprocessing nima?

Follow-up:

1. Nega preprocessing muhim?
2. Missing values nima?
3. Null qiymatlarni qanday tozalash mumkin?
4. Duplicate data qanday aniqlanadi?
5. Outlierlarni qanday topish mumkin?

2-savol: Feature scaling nima?

Follow-up:

1. Standardization nima?
2. Normalization nima?
3. Scaling qachon kerak bo'ladi?
4. Qaysi algoritmlar scaling talab qiladi?
5. MinMaxScaler qanday ishlaydi?

3-savol: Encoding nima?

Follow-up:

1. Label Encoding nima?
2. One-Hot Encoding nima?
3. Categorical data nima?
4. Encoding qachon ishlatiladi?
5. Pandas'da encoding qanday qilinadi?

4-savol: Train-test split nima?

Follow-up:

1. Dataset nima uchun bo'linadi?
2. Training data nima?
3. Testing data nima?
4. Validation data nima?
5. sklearn'da train_test_split qanday ishlaydi?

2. Classification uchun K-Fold

Dataset:

Iris dataset

Kod:

```
from sklearn.datasets import load_iris
from sklearn.model_selection import KFold, cross_val_score
from sklearn.tree import DecisionTreeClassifier

# Dataset
iris = load_iris()
X = iris.data
y = iris.target

# Model
model = DecisionTreeClassifier()

# KFold
kf = KFold(n_splits=5, shuffle=True, random_state=42)

# Cross validation
scores = cross_val_score(model, X, y, cv=kf)

print("Scores:", scores)
print("Average Accuracy:", scores.mean())
```

Natija:

- Dataset 5 qismga bo'linadi
- Har safar boshqa qism test bo'ladi
- Accuracy o'rtachasi hisoblanadi

3. Regression uchun K-Fold

Dataset:

California Housing dataset

Kod:

```
from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import KFold, cross_val_score
from sklearn.linear_model import LinearRegression

# Dataset
data = fetch_california_housing()

X = data.data
y = data.target

# Model
model = LinearRegression()

# KFold
kf = KFold(n_splits=5, shuffle=True, random_state=42)

# Cross validation
scores = cross_val_score(model, X, y, cv=kf, scoring='r2')

print("R2 Scores:", scores)
print("Average R2:", scores.mean())
```

Natija:

- Regression model baholanadi
- R^2 score hisoblanadi
- O'rtacha performance chiqariladi

Xulosa

K-Fold Cross Validation modelning ishonchliligini tekshiradi. Dataset bir necha qismga bo'linib, model bir necha marta train va test qilinadi. Bu usul overfittingni kamaytirishga yordam beradi.

1-savol: Data preprocessing nima?

Javob:

Data preprocessing — bu datasetni machine learning model uchun tayyorlash jarayoni. Bu bosqichda data tozalanadi, tartiblanadi va model ishlashi uchun mos holatga keltiriladi.

Follow-up javoblari:

1. Nega preprocessing muhim?

Chunki notoza yoki xato data model aniqligini pasaytiradi.

2. Missing values nima?

Datasetdagi bo'sh yoki yo'q qiymatlar.

3. Null qiymatlarni qanday tozalash mumkin?

- O'chirib tashlash
- O'rtacha qiymat bilan to'ldirish
- Median bilan almashtirish

4. Duplicate data qanday aniqlanadi?

Bir xil takrorlangan qatorlarni tekshirish orqali.

5. Outlierlarni qanday topish mumkin?

- Boxplot
- IQR usuli
- Z-score orqali

2-savol: Feature scaling nima?

Javob:

Feature scaling — sonli qiymatlarni bir xil diapazonga keltirish jarayoni.

Follow-up javoblari:

1. Standardization nima?

Ma'lumotni o'rtacha 0 va standard deviation 1 qilish usuli.

2. Normalization nima?

Qiymatlarni 0 va 1 oralig'iga olib kelish.

3. Scaling qachon kerak bo'ladi?

KNN, SVM, Logistic Regression kabi algoritmlarda.

4. Qaysi algoritmlar scaling talab qiladi?

- KNN
- SVM
- Neural Network

- Logistic Regression

5. MinMaxScaler qanday ishlaydi?

Eng kichik qiymatni 0, eng kattasini 1 qiladi.

3-savol: Encoding nima?

Javob:

Encoding — categorical data'ni sonli ko'rinishga o'tkazish jarayoni.

Follow-up javoblari:

1. Label Encoding nima?

Har bir kategoriya uchun son beriladi.

Misol:

- Red = 0
- Blue = 1

2. One-Hot Encoding nima?

Har kategoriya uchun alohida ustun yaratadi.

3. Categorical data nima?

Matn yoki kategoriya ko'rinishidagi ma'lumot.

4. Encoding qachon ishlatiladi?

Model matnni tushunmaganda.

5. Pandas'da encoding qanday qilinadi?

`get_dummies()` funksiyasi orqali.

4-savol: Train-test split nima?

Javob:

Datasetni training va testing qismlarga bo'lish jarayoni.

Follow-up javoblari:

1. Dataset nima uchun bo‘linadi?

Modelni tekshirish uchun.

2. Training data nima?

Model o‘rganadigan qism.

3. Testing data nima?

Model sinovdan o‘tadigan qism.

4. Validation data nima?

Model parametrlarini tekshirish uchun ishlatiladi.

5. sklearn’da train_test_split qanday ishlaydi?

Misol:

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

Bu yerda:

- 80% training
- 20% testing data bo‘ladi.